

Técnicas para análisis automático de forma en cerámicas ibéricas basado en Morfometría Geométrica y Aprendizaje Profundo

Celia Cintas¹, Manuel Lucena², José Manuel Fuertes², Pablo Navarro³, Claudio Delrieux⁴, Manuel Molinos⁵, Rolando González-José³

¹IBM Research Africa, Nairobi, Kenya.

²Department of Computer Science, University of Jaén, Spain.

³Instituto Patagónico de Ciencias Sociales y Humanas, CENPAT-CONICET, Argentina

⁴Departamento de Ingeniería Eléctrica y de Computadoras, UNS-CONICET, Argentina

⁵Research University Institute for Iberian Archeology, University of Jaén, Spain

CONICET



IBM Research | Africa



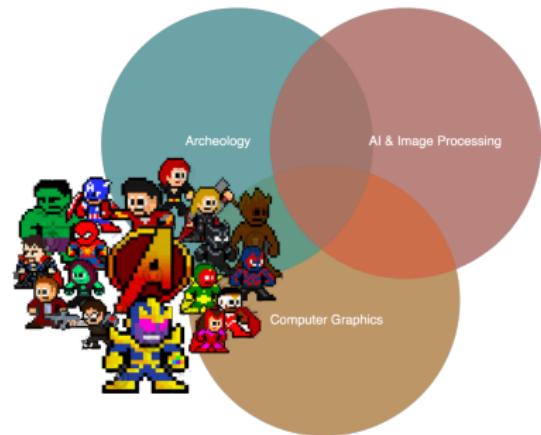
UNIVERSIDAD DE JAÉN

- 1 Introducción
 - El Equipo
 - Qué es Aprendizaje Profundo?
 - Dataset
 - Trabajos Previos
- 2 Clasificación Automática de vasijas ibéricas
- 3 Aprendizaje automático de representaciones
- 4 Generación sintética de vasijas para estudio de fragmentos
- 5 Trabajo Futuro





- ▶ José Manuel Fuertes García
- ▶ Manuel Lucena López
- ▶ Antonio Rueda Ruiz
- ▶ Carlos Ogáyar Anguita
- ▶ Rafael Segura Sánchez
- ▶ Manuel Molinos Molinos
- ▶ Arturo Ruiz Rodríguez
- ▶ Claudio Delrieux
- ▶ Pablo Navarro
- ▶ Rolando Gonzalez-José
- ▶ Celia Cintas



Dibujo de @cabzcbzrs

Introducción al Aprendizaje Profundo

El Aprendizaje profundo ha logrado grandes avances en el ámbito de la ciencia, incluyendo el **reconocimiento de imágenes** [FCNL13, TJLB14, SLJ⁺15], reconocimiento **del habla** [MDP⁺11, HSK⁺12], el análisis de datos del **acelerador de partículas** [SBW14], la reconstrucción de circuitos del cerebro [HBT⁺13], predicción de efectos en **mutaciones npn-coding DNA** en expresión genética y enfermedades [LXLF14, XAL⁺15] y muchos otros contextos más.

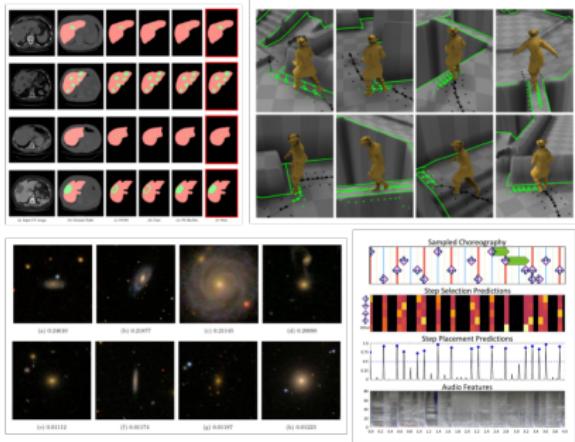


Figura 1: Examples from [DLM17, DWD15, HKS17, CQSA⁺16]

Introducción al Aprendizaje Profundo (Cont.)

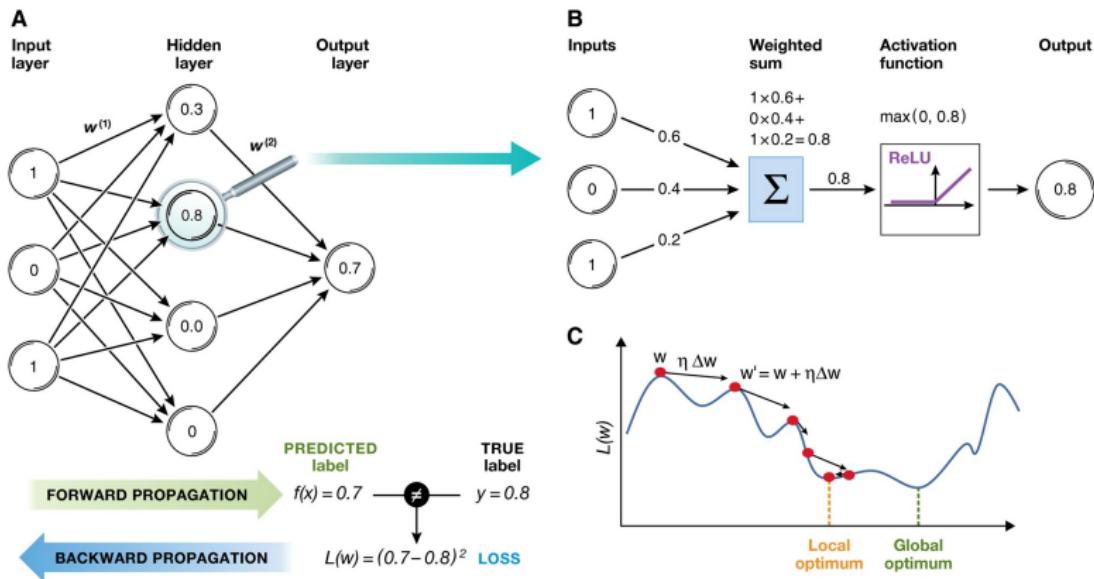
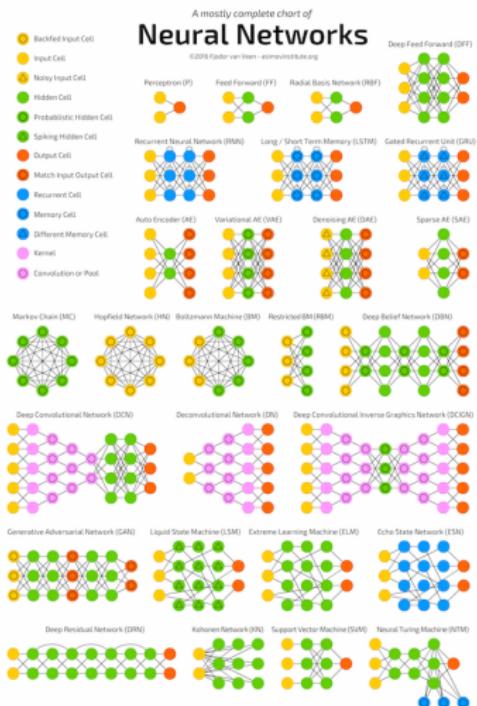


Figura 2: Arquitectura y $L(w)$ de red perceptron [APPS16].

Introducción al Aprendizaje Profundo (Cont.)

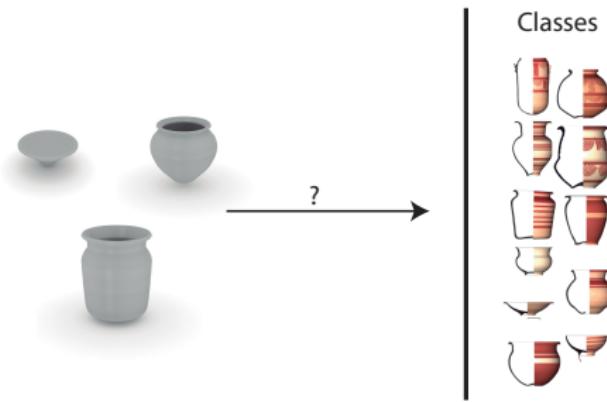


- Redes Neuronales **Convolucionales** (clasificación de vasijas)
- Redes Neuronales **Residuales** (mejores representaciones de vasijas)
- Redes Neuronales **Adversarias Generativas** (generación sintética de vasijas)

Figura 3: Diagrama de
www.asimovinstitute.org

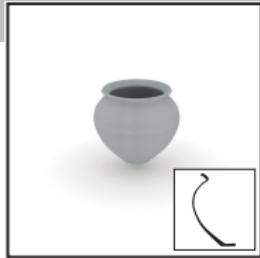
Clasificación Automática de vasijas ibéricas

Los restos cerámicos proporcionan valiosa información que ayuda a datar el estrato arqueológico donde se encuentran, aportando **evidencias** de la producción local, relaciones comerciales, comportamiento de consumidores en poblaciones locales, etc. [OTV93, KS03]. Analizar y poder comparar artefactos de una manera **cuantitativa** es un tema relevante en estudios arqueológicos actuales.

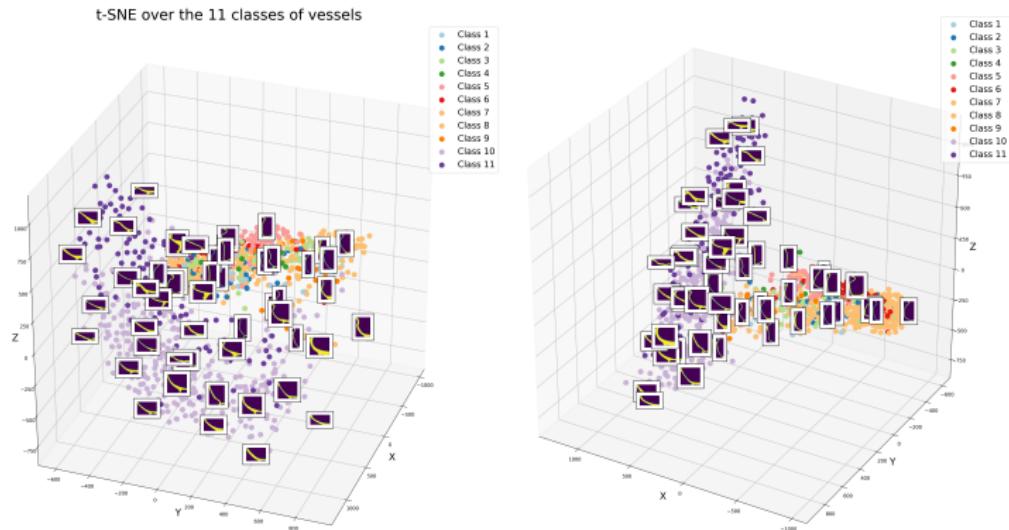


Dataset

La colección está formada por **vajillas cerámicas de torno** encontradas en diversos yacimientos arqueológicos ibéricos ubicados en el Valle del Alto Guadquivir (España). Está compuesta por unos miles de distintos recipientes, de los que se han registrado y clasificado **sus perfiles 2D proyectados** (vista lateral de cada una de ellas). La clasificación fue hecha en base a **criterios morfológicos** por un grupo de expertos [LMCF⁺14].



Dataset (Cont.)



Podemos observar dos grandes conjuntos de vasijas, vasijas con formas cerradas (clases 1 a 9), el segundo cluster es de formas abiertas (clases 10 y 11).

Trabajos Previos

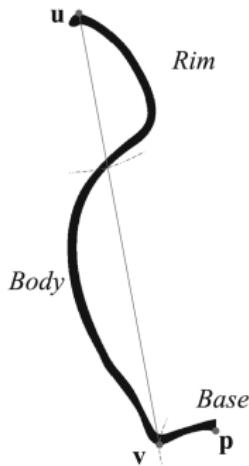


Figura 4:
Segmentación
borde, base y
cuerpo
[LMCF⁺14].

Método de caracterización de forma y tamaño con distancias euclídeas sobre operaciones morfológicas (erosión, dilatación, apertura, etc.) para clasificación de vasijas [LMCF⁺14, LFMC⁺16].

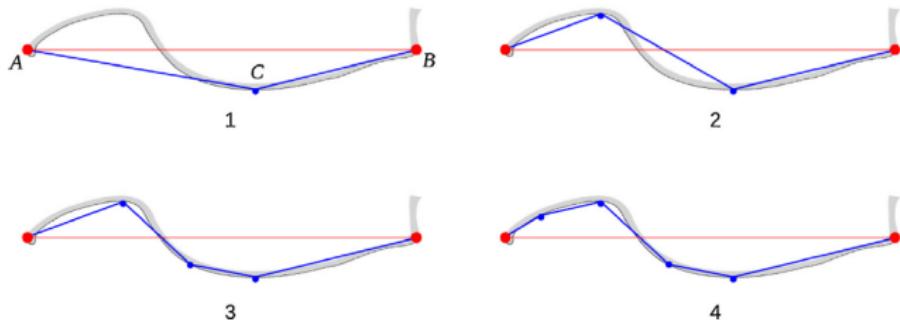
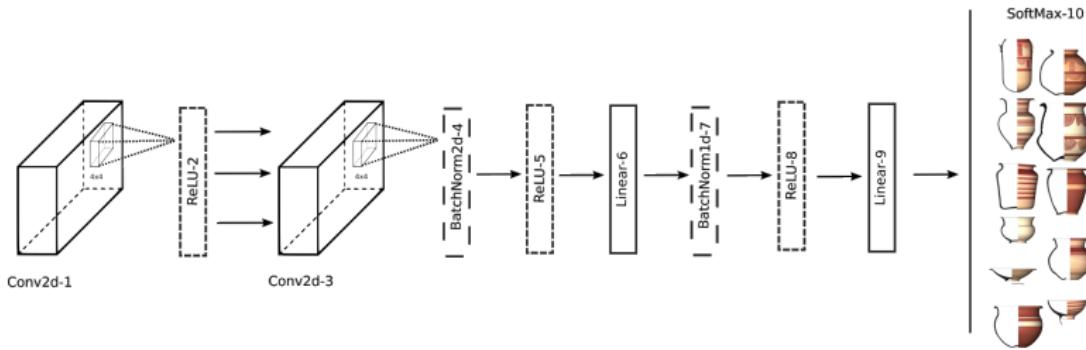


Figura 5: Curvas simplificadas [LFMC⁺16].

Utilizando Redes Convolucionales para extraer características y tipificar vasijas.

Una arquitectura clásica de **ConvNet** [Fuk80, LBBH98] está dada por dos etapas. La primer etapa se enfoca en **extraer** características discriminantes a distintos niveles de abstracción, y la segunda se enfoca en la **clasificación** a partir de las características obtenidas previamente.



Available online at
ScienceDirect
www.sciencedirect.com

Elsevier Masson France
EM|consulte
www.em-consulte.com/en



Original article

Automatic feature extraction and classification of Iberian ceramics
based on deep convolutional networks

Celia Cintas^{a,*}, Manuel Lucena^b, José Manuel Fuertes^b, Claudio Delrieux^c,
Pablo Navarro^{d,1}, Rolando González-José^d, Manuel Molinos^e

Técnicas para mejorar la Generalización

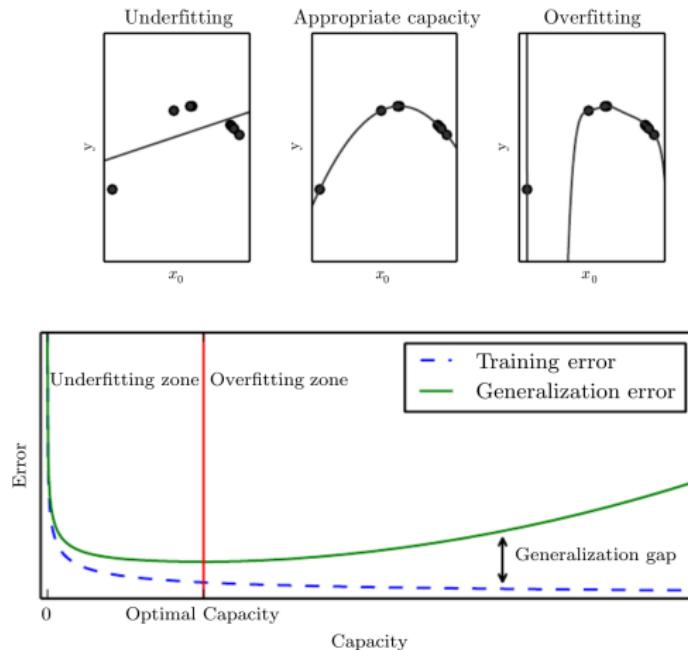
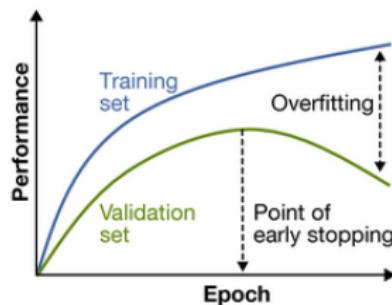
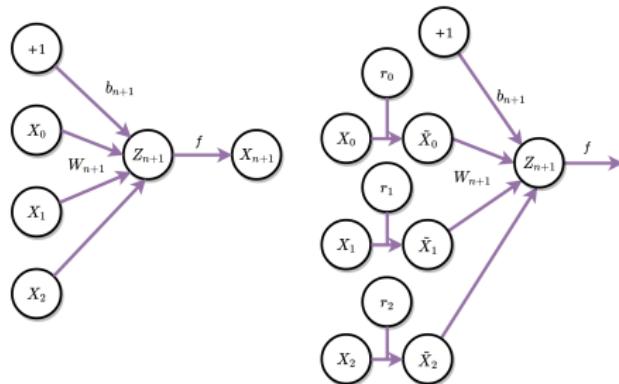


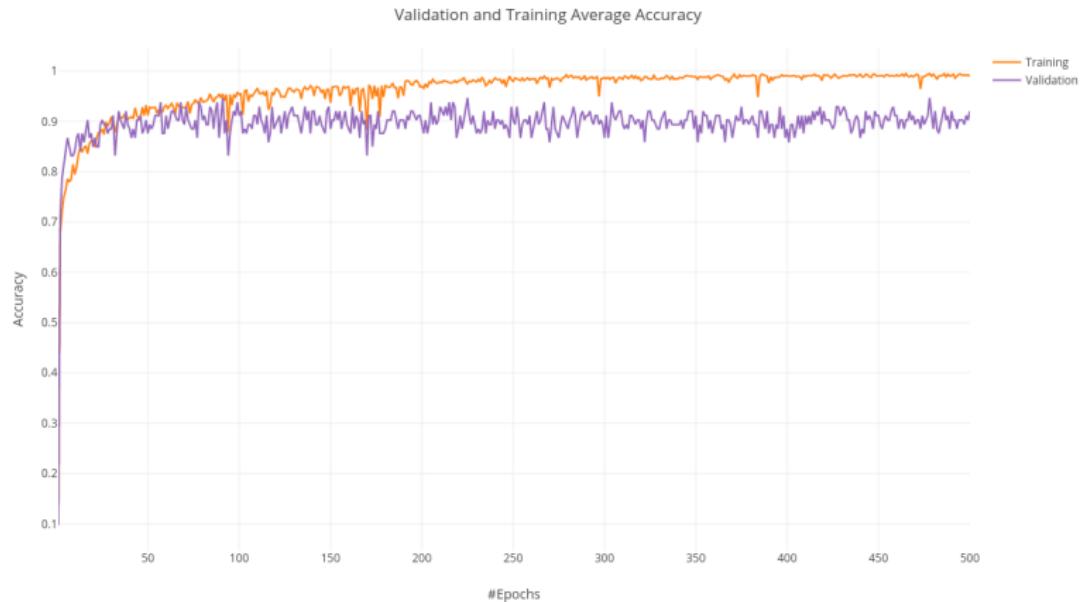
Figura 6: Capacidad, *overfitting* y *underfitting* [IGC16].

Técnicas para mejorar la Generalización (Cont.)

- ▶ Dropout [HSK⁺12].
- ▶ Detención Temprana.
- ▶ Transferencia de conocimiento (*).
- ▶ Aumento artificial de datos (**).

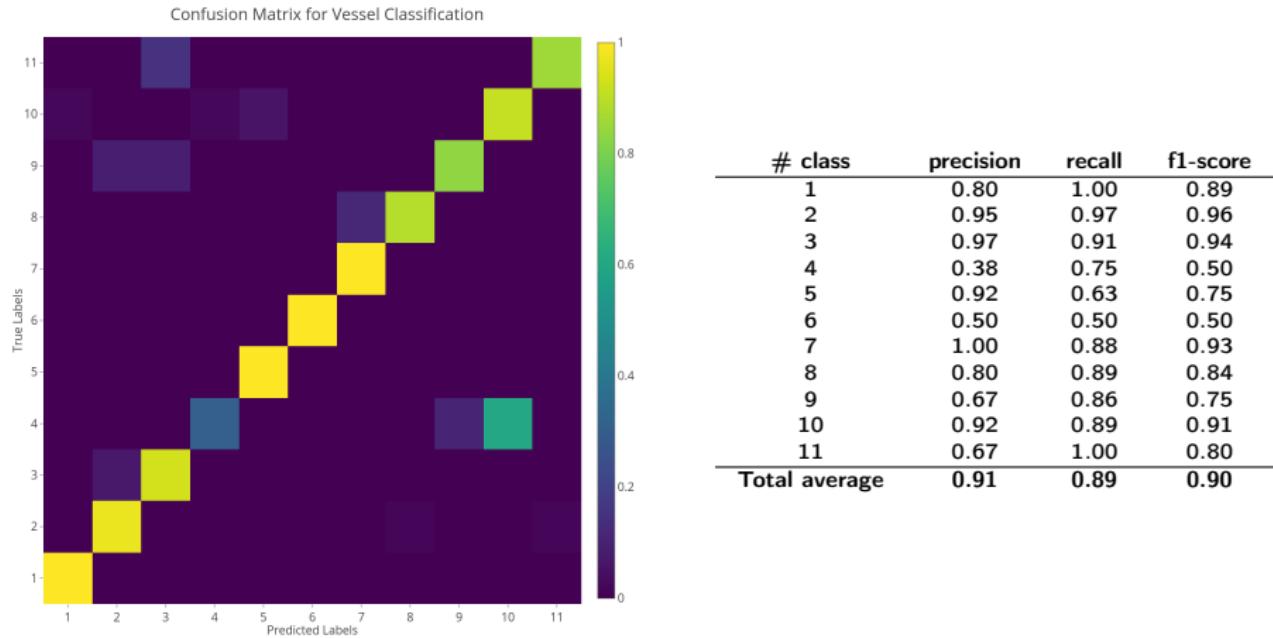


Entrenamiento de Redes Profundas (Cont.)



Curvas de exactitud promedio en datos de entrenamiento y validación sobre la Red Convolucional.

Resultados



Buscando una mejor representación con transferencia de conocimiento y Redes Residuales

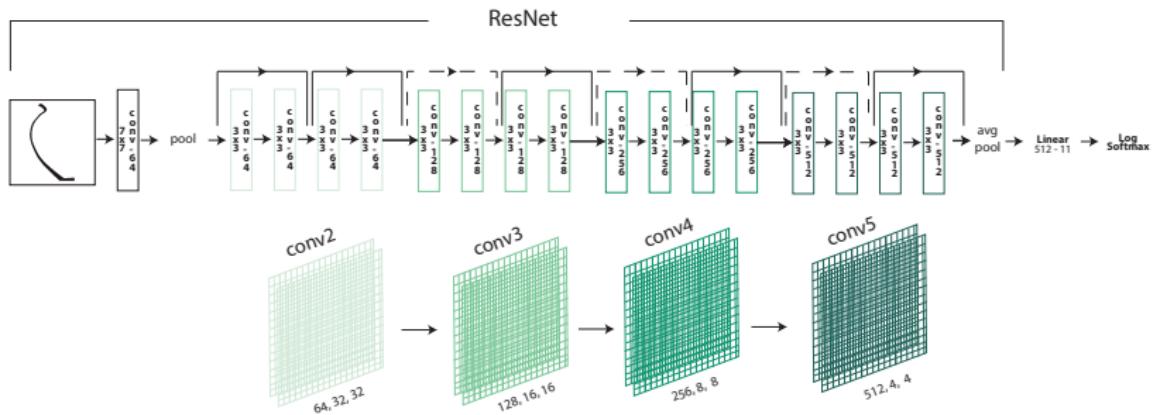


Figura 7: Arquitectura de Red Residual ResNet-18 [HZRS16] modificada para clasificación de vasijas mediante transferencia de conocimiento.

Buscando una mejor representación con transferencia de conocimiento (Cont.)

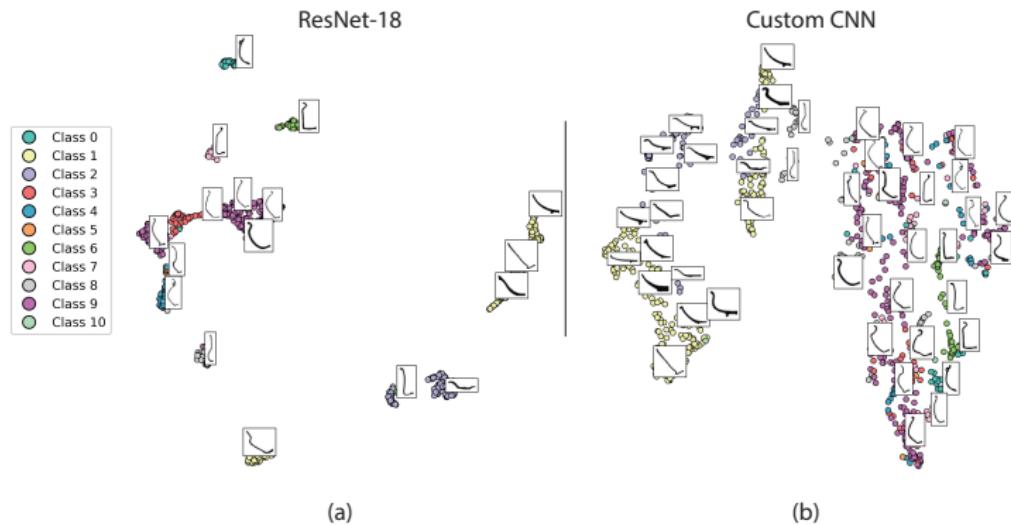


Figura 8: Visualización UMAP de espacios de representación generados por redes neuronales: (a) Red residual con transferencia de conocimiento (Bajo revisión en *Journal of Cultural Heritage*, Navarro et al.), (b) red convolucional [CLF⁺19].

Buscando una mejor representación con transferencia de conocimiento (Cont.)

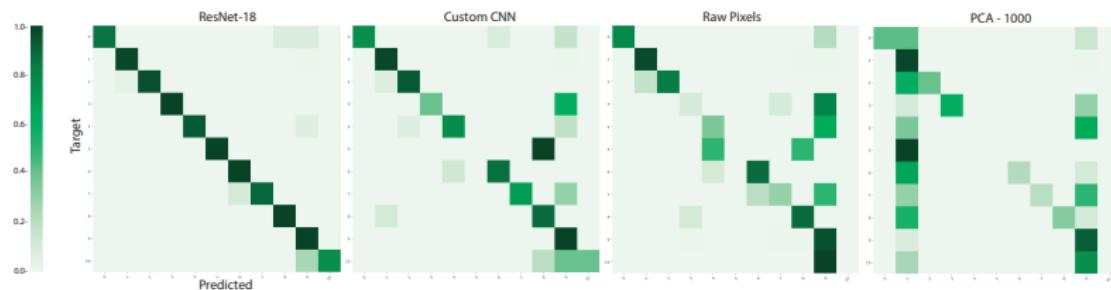


Table 1. Precision, f_1 and recall over the test set for SVM and RFC with each variant of feature representation methods. For the custom CNN trained from scratch we used the implementation presented at (Cintas et al., 2019). Our approach uses transfer learning from ResNet-18 (He et al., 2016) and retrain for the pottery classification purposes. More details on how the models were trained at Section 2.2.

Method	SVM			RFC			
	Precision	f_1	Recall	Precision	f_1	Recall	
ResNet-18	0.98 (± 0.02)	0.96 (± 0.02)	0.95 (± 0.03)	0.87 (± 0.04)	0.81 (± 0.06)	0.81 (± 0.04)	
Custom CNN	0.82 (± 0.07)	0.72 (± 0.05)	0.71 (± 0.04)	0.51 (± 0.09)	0.35 (± 0.03)	0.35 (± 0.03)	
Raw Pixels	0.69 (± 0.08)	0.60 (± 0.05)	0.59 (± 0.05)	0.44 (± 0.04)	0.39 (± 0.03)	0.41 (± 0.04)	
600	0.59 (± 0.08)	0.35 (± 0.06)	0.33 (± 0.05)	0.23 (± 0.09)	0.15 (± 0.04)	0.19 (± 0.01)	
PCA	800	0.62 (± 0.09)	0.37 (± 0.06)	0.35 (± 0.04)	0.21 (± 0.08)	0.15 (± 0.03)	0.19 (± 0.02)
900	0.66 (± 0.12)	0.40 (± 0.07)	0.36 (± 0.05)	0.19 (± 0.01)	0.15 (± 0.03)	0.19 (± 0.01)	
1000	0.75 (± 0.01)	0.47 (± 0.07)	0.42 (± 0.06)	0.20 (± 0.01)	0.15 (± 0.02)	0.19 (± 0.02)	

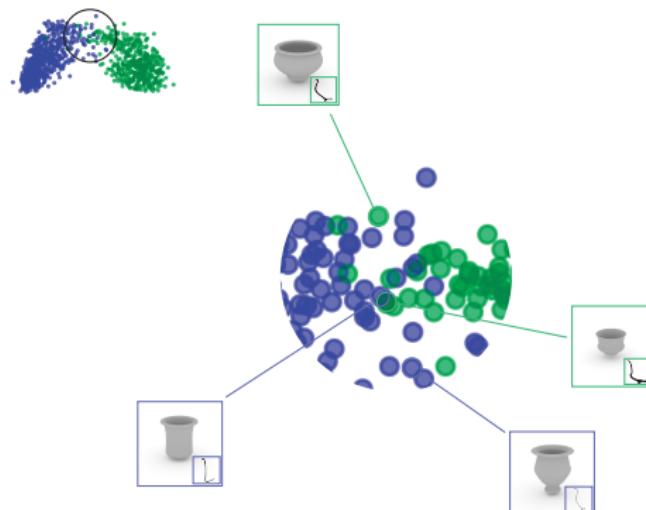
Aprendizaje no supervisado basado en Semilandmarks

CAA
2019

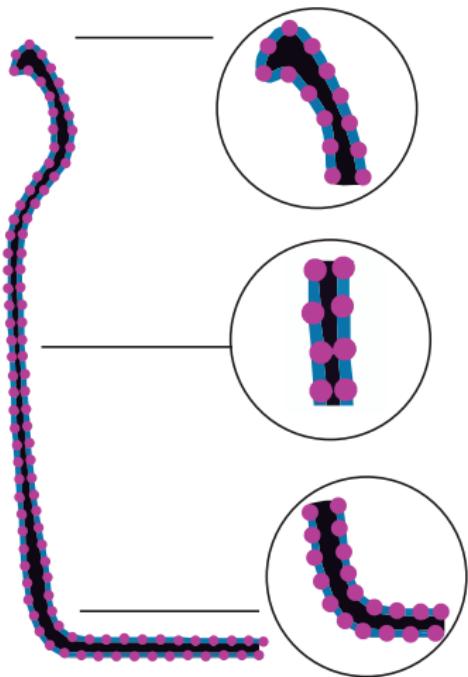
Standard session 44: Analysing Shape in the Digital Age: Current Considerations in Archaeological Application of Geometric Morphometrics

Unsupervised techniques for shape analysis of Iberian ceramics based on Geometric Morphometrics

Pablo Navarro, Celia Cintas, Manuel Lucena, Jose Manuel Fuertes, Claudio Delrieux, Manuel Molinos Mail



Semi-landmark Extraction

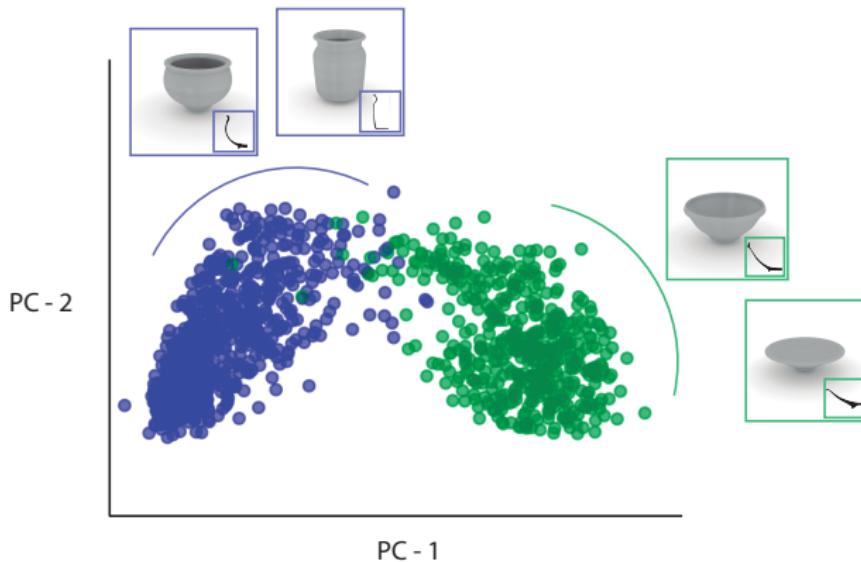


- ① La extracción del contorno fue hecha con *Marching squares algorithm* de Scikit-Image. [vdWSN⁺14, LC87]
- ② 200 Semi-landmarks anotados de forma equidistante a lo largo de la curva generada por el contorno.

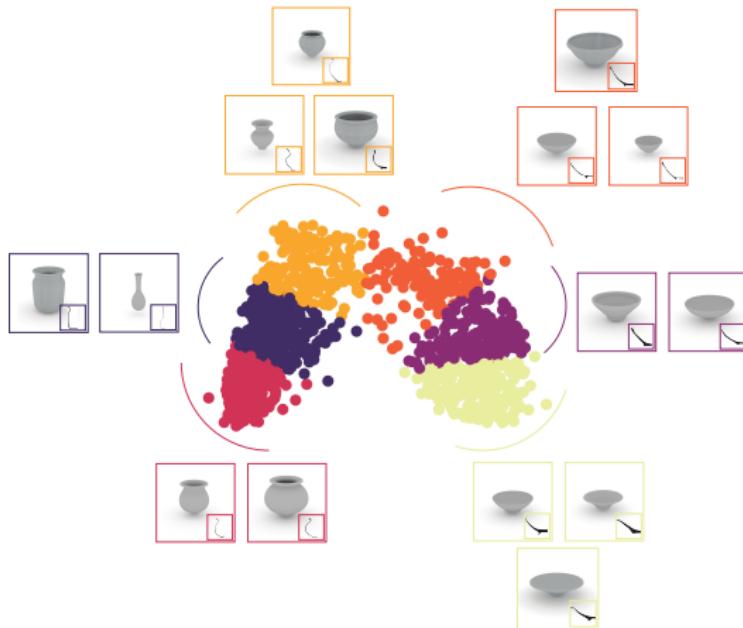
<https://github.com/celiacintas/vasijas>

Principal component analysis (PCA)

Podemos ver los primeros 2 PCs de semilandmarks generados automáticamente.



Clustering

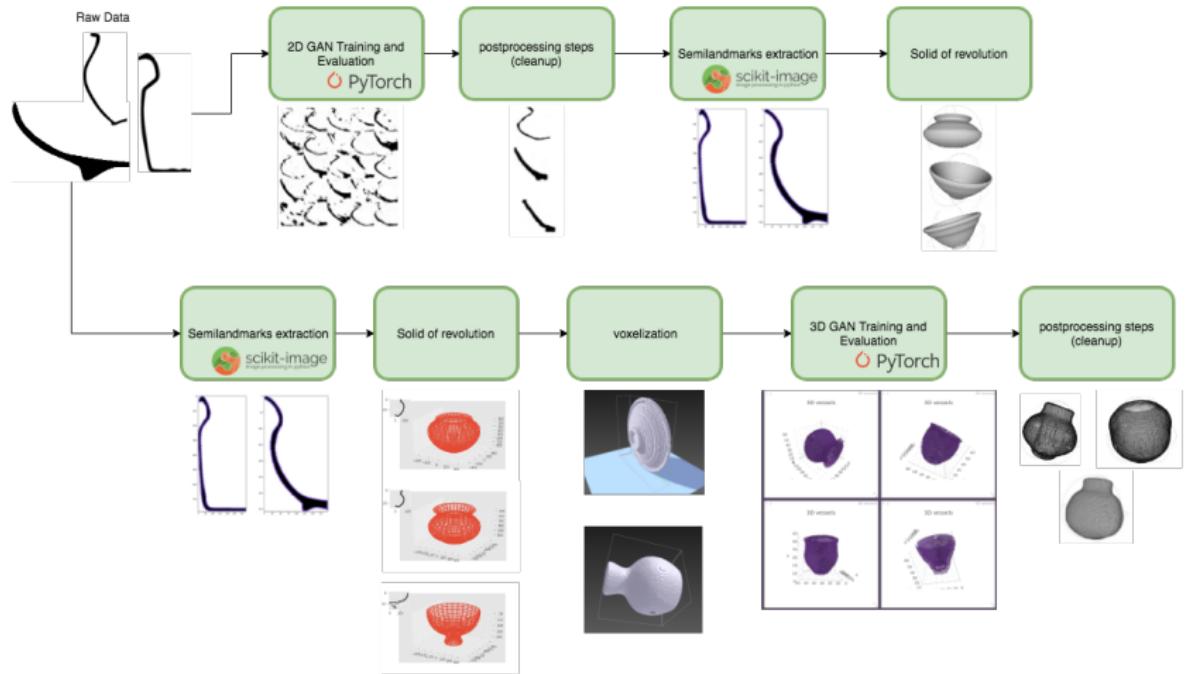


En lugar de presentar una clase de la nueva vasija, proponemos darle al experto un **enfoque interactivo** para navegar un conjunto de artefactos de cerámica bajo un rango de **similitud** dentro de un *cluster*.

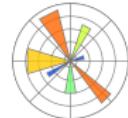
Generación sintética de vasijas para estudio de fragmentos

Desafortunadamente, la cerámica es frágil, por lo que la gran parte de las vasijas recuperadas de los sitios arqueológicos están quebradas, la gran mayoría del material disponible esta fragmentado.

Cómo generamos nuevas muestras 3D?



¿Qué bibliotecas de Python usamos para implementar nuestros experimentos?



Qué son las redes Generativas Adversarias?

$\min_{\text{roca}} \max_{\text{indiana}} V(\text{indiana}, \text{roca}) = \text{distancia entre ellos}$

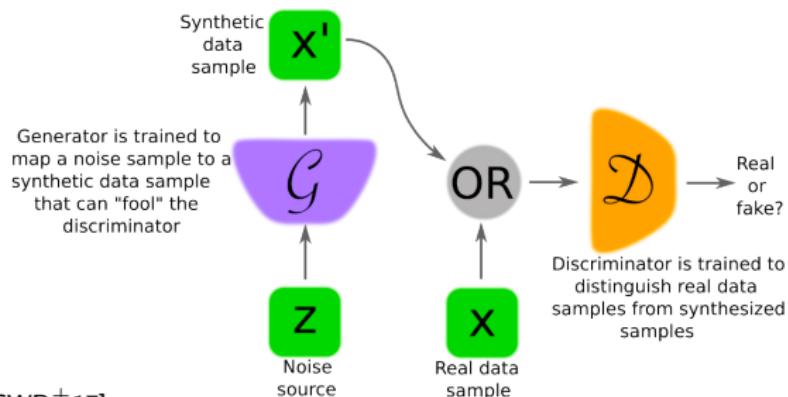


Imagen de [CWD⁺17]

Salidas generadas y Evaluación de GANs 2D

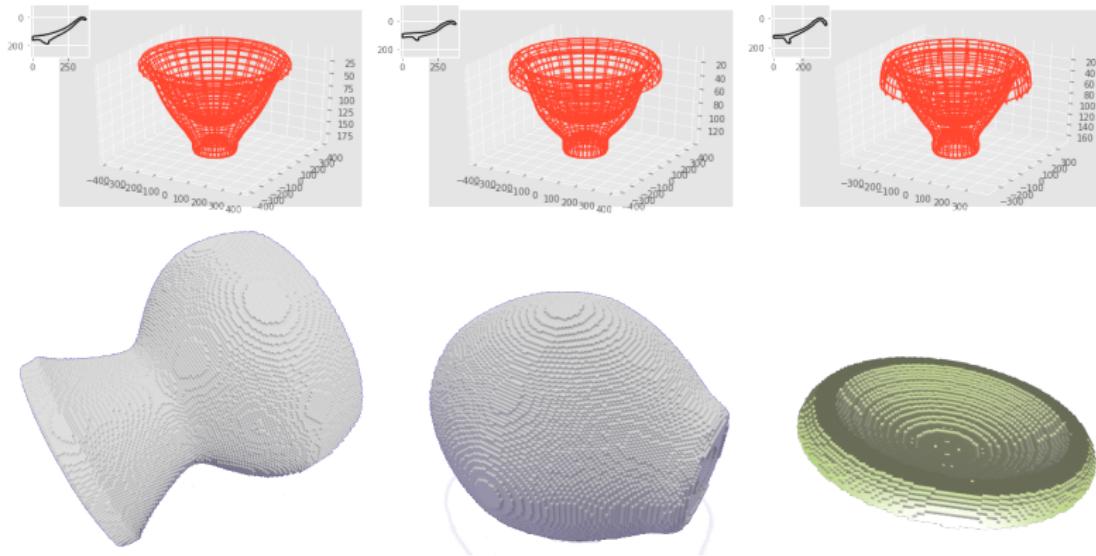


- ① Entrenar una CGAN para generar muestras de clases específicas.
- ② Muestras generadas son utilizadas como entrada 🍷 de nuestro clasificador [CLF⁺19]. Este evaluó correctamente 1k de vasijas. (accuracy = 0.89)
- ③ PCA de muestras reales y generadas.

Entrenando una 3DGAN

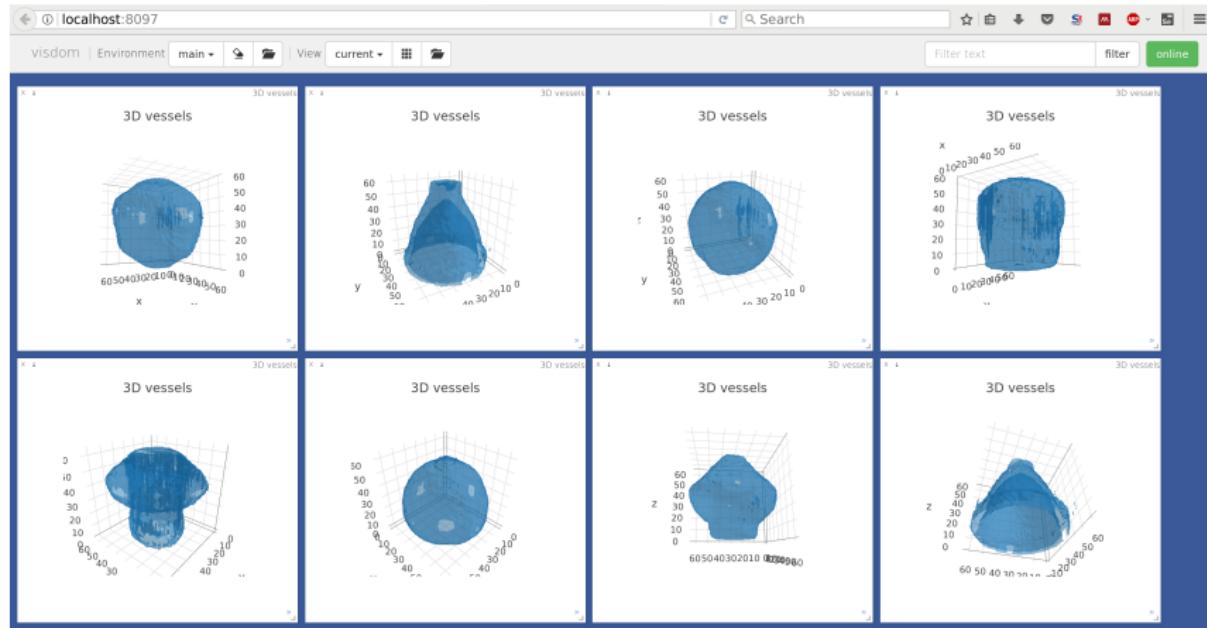
La idea de usar 3DGANs es trabajar directamente en el **espacio volumétrico**. Varias bases de datos están digitalizadas con sensores 3D. La mayoría de los fragmentos se encontrarán en este formato. Queremos reducir pasos de pre-procesamiento.

Revolución de Sólidos & Voxelización



https://github.com/celiacintas/vasijas/blob/master/surface_generation.ipynb

Visualizando la salida generada por nuestra 3DGAN



Trabajo Futuro

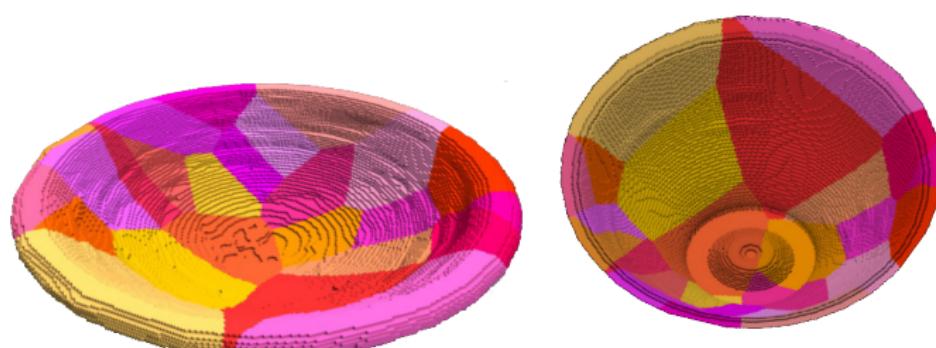
Comparar 2DGAN + revolución de sólidos > 3DGAN + remeshing

Que método genera vasijas ibéricas más realistas.

VAE-3DGAN Podemos identificar (clasificar + ubicación en el espacio) a partir de una sola vista 2D?.

Clasificación de fragmentos Hasta que tamaño la red es capaz de localizar fragmentos?

Agregar Información de Textura Cómo podemos integrar información sobre la textura a la información geométrica que tenemos?

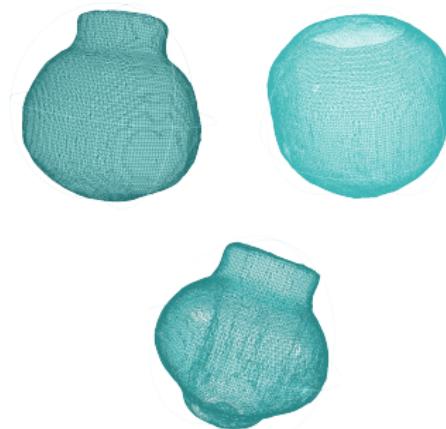


Links interesantes

ConvNets y Vasijas <https://doi.org/10.1016/j.culher.2019.06.005>

//doi.org/10.1016/j.culher.2019.06.005

Github Repo <https://github.com/celiacintas/vasijas>



Contactos: jmf@ujaen.es, mlucena@ujaen.es, cad@uns.edu.ar,
celia.cintas@ibm.com, pnavarro@cenpat-conicet.gob.ar

References I

-  Christof Angermueller, Tanel Pärnamaa, Leopold Parts, and Oliver Stegle, *Deep learning for computational biology*, Molecular Systems Biology **12** (2016), no. 7, 878–n/a, 878.
-  Celia Cintas, Manuel Lucena, José Manuel Fuertes, Claudio Delrieux, Pablo Navarro, Rolando González-José, and Manuel Molinos, *Automatic feature extraction and classification of iberian ceramics based on deep convolutional networks*, Journal of Cultural Heritage (2019).

References II

-  Celia Cintas, Mirsha Quinto-Sánchez, Victor Acuña, Carolina Paschetta, Soledad De Azevedo, Caio Silva de Cerqueira, Virginia Ramallo, Carla Gallo, Giovanni Poletti, Maria Catira Bortolini, Samuel Canizales-Quinteros, Rothhammer Francisco, Gabriel Bedoya, Andres Ruiz-Linares, Rolando Gonzaléz-José, and Claudio Delrieux, *Automatic ear detection and feature extraction using Geometric Morphometrics and Convolutional Neural Networks*, IET Biometrics (2016).
-  Antonia Creswell, Tom White, Vincent Dumoulin, Kai Arulkumaran, Biswa Sengupta, and Anil A. Bharath, *Generative adversarial networks: An overview*, CoRR **abs/1710.07035** (2017).
-  Chris Donahue, Zachary C. Lipton, and Julian McAuley, *Dance Dance Convolution*.

References III

-  S. Dieleman, K. W. Willett, and J. Dambre, *Rotation-invariant convolutional neural networks for galaxy morphology prediction*, Monthly Notices of the Royal Astronomical Society **450** (2015), no. 2, 1441–1459.
-  Clement Farabet, Camille Couprie, Laurent Najman, and Yann Lecun, *Learning hierarchical features for scene labeling*, IEEE Transactions on Pattern Analysis and Machine Intelligence **35** (2013), no. 8, 1915–1929.
-  Kunihiko Fukushima, *Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position*, Biological Cybernetics **36** (1980), no. 4, 193–202.
-  Moritz Helmstaedter, Kevin L Briggman, Srinivas C Turaga, Viren Jain, H Sebastian Seung, and Winfried Denk, *Connectomic reconstruction of the inner plexiform layer in the mouse retina*, Nature **500** (2013), no. 7461, 168–174.

References IV

-  Daniel Holden, Taku Komura, and Jun Saito, *Phase-functioned neural networks for character control*, ACM Trans. Graph. **36** (2017), no. 4, 42:1–42:13.
-  Geoffrey E. Hinton, Nitish Srivastava, Alex Krizhevsky, Ilya Sutskever, and Ruslan R. Salakhutdinov, *Improving neural networks by preventing co-adaptation of feature detectors*, arXiv: 1207.0580 (2012), 1–18.
-  Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun, *Deep residual learning for image recognition*, The IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 2016.
-  Yoshua Bengio Ian Goodfellow and Aaron Courville, *Deep learning*, Book in preparation for MIT Press, 2016.

References V

-  M. Kampel and R. Sablatnig, *An automated pottery archival and reconstruction system*, Journal of Visualization and Computer Animation **14** (2003), no. 3, 111–120.
-  Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner, *Gradient-based learning applied to document recognition*, Proceedings of the IEEE **86** (1998), no. 11, 2278–2323.
-  William E. Lorensen and Harvey E. Cline, *Marching cubes: A high resolution 3D surface construction algorithm*, ACM SIGGRAPH Computer Graphics (1987).
-  Manuel Lucena, Jose Manuel Fuertes, Ana Luisa Martinez-Carrillo, Arturo Ruiz, and Francisco Carrascosa, *Efficient classification of Iberian ceramics using simplified curves*, Journal of Cultural Heritage **19** (2016), 538–543.

References VI

-  M. Lucena, A. L. Martínez-Carrillo, J.M. Fuertes, F. Carrascosa, and A. Ruiz, *Decision support system for classifying archaeological pottery profiles based on mathematical morphology*, *Multimedia Tools and its Applications* (2014).
-  Michael K K Leung, Hui Yuan Xiong, Leo J. Lee, and Brendan J. Frey, *Deep learning of the tissue-regulated splicing code*, *Bioinformatics* **30** (2014), no. 12.
-  Tomáš Mikolov, Anoop Deoras, Daniel Povey, Lukáš Burget, and Jan Černocký, *Strategies for training large scale neural network language models*, *2011 IEEE Workshop on Automatic Speech Recognition and Understanding, ASRU 2011*, Proceedings, 2011, pp. 196–201.
-  C. Orton, P. Tyers, and A. Vinci, *Pottery in Archaeology*, Cambridge University Press, United Kingdom, 1993.

References VII

-  Peter Sadowski, Pierre Baldi, and Daniel Whiteson, *Searching for Higgs Boson Decay Modes with Deep Learning*, Advances in Neural Information Processing Systems 27 (Proceedings of NIPS) (2014), 1–9.
-  Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich, *Going deeper with convolutions*, Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, vol. 07-12-June-2015, 2015, pp. 1–9.
-  Jonathan Tompson, Arjun Jain, Yann LeCun, and Christoph Bregler, *Joint Training of a Convolutional Network and a Graphical Model for Human Pose Estimation*, Advances in neural information processing systems (2014), 1799—1807.

References VIII

-  Stéfan van der Walt, Johannes L. Schönberger, Juan Nunez-Iglesias, François Boulogne, Joshua D. Warner, Neil Yager, Emmanuelle Gouillart, Tony Yu, and the scikit-image contributors, *scikit-image: image processing in Python*, PeerJ **2** (2014), e453.
-  Hui Y. Xiong, Babak Alipanahi, Leo J. Lee, Hannes Bretschneider, Daniele Merico, Ryan K. C. Yuen, Yimin Hua, Serge Gueroussov, Hamed S. Najafabadi, Timothy R. Hughes, Quaid Morris, Yoseph Barash, Adrian R. Krainer, Nebojsa Jojic, Stephen W. Scherer, Benjamin J. Blencowe, and Brendan J. Frey, *The human splicing code reveals new insights into the genetic determinants of disease.*, Science **347** (2015), no. 6218, 1254806.